

# Relatório — Calibração de Forecast do Modelo (PnL)

Data: 2026-01-16

Fonte numérica: forecast\_calibration\_global\_bayes.csv (folds: 16)

## 1. O que estamos medindo

Para cada semana do walk-forward, o modelo escolhe regras  $\theta_t$  usando apenas o passado. Em seguida medimos se a **distribuição prevista** para o PnL semanal está coerente com o **PnL teórico realizado** (aplicando  $\theta_t$  na semana teste).

**Importante:** isso é uma calibração “teórico vs teórico”. Ela mede qualidade do modelo como gerador de decisão+previsão no dataset, mas não captura fricções de execução real (atraso, liquidez, limites dinâmicos, etc.).

## 2. Métricas de erro (pontuais)

**Erro:**  $e_t = y_t - \hat{\mu}_t$ , onde  $y_t$  é o PnL teórico realizado e  $\hat{\mu}_t$  é a média prevista.

**Bias (viés):** média do erro. Se Bias < 0, o modelo está **otimista** (prevendo PnL maior do que realiza).

**MAE:** erro absoluto médio. Medida robusta de “tamanho típico” do erro.

**RMSE:** raiz do erro quadrático médio. Penaliza mais os erros grandes (sensível a outliers).

### Resumo numérico (PnL semanal)

| Bias       | MAE       | RMSE      |
|------------|-----------|-----------|
| USD -181.3 | USD 380.9 | USD 449.1 |

## 3. Métricas probabilísticas (calibração)

**Coverage:** frequência com que o realizado cai dentro do intervalo previsto. Ex.: Coverage 80% mede quantas vezes  $y_t$  cai entre p10 e p90 do preditivo. Se o modelo for bem calibrado, a coverage observada deve ficar próxima do nível nominal (80%/90%).

**PIT** (Probability Integral Transform): para cada semana, calcula  $\text{PIT}_t = F_t(y_t)$ , ou seja, a posição do realizado dentro da CDF prevista. Se a distribuição prevista for correta, os PITs ao longo do tempo se comportam como Uniforme(0,1) (média ~0,5). PIT muito baixo indica que o realizado veio pior do que o previsto; PIT muito alto indica o oposto.

**CRPS** (Continuous Ranked Probability Score): mede a distância entre a distribuição prevista e o realizado. Generaliza o MAE para previsões probabilísticas. **Menor é melhor.**

| Coverage 80% (p10..p90) | Coverage 90% (p05..p95) | PIT (média) | CRPS (médio) |
|-------------------------|-------------------------|-------------|--------------|
| 50.0%                   | 62.5%                   | 0.375       | USD 260.3    |

## 4. Por que o PnL previsto pode “inflar” (Stake vs ROI)

Como  $\text{PnL} = \text{Stake} \times \text{ROI}$ , um forecast pode parecer otimista por dois caminhos:

- o modelo projeta **stake** alto (mais volume do que acontece)
- o modelo projeta **ROI** alto (retorno por dólar piora)

No nosso caso, o preditivo é gerado reamostrando semanas passadas (bootstrap Bayesiano), então o modelo aprende uma distribuição conjunta (Stake, ROI) implícita.

### Decomposição (médias)

Uma decomposição útil para o erro semanal  $(y - \hat{P})$  é:

$$(y - \hat{P}) = (S - \hat{S})\hat{R} + \hat{S}(R - \hat{R}) + (S - \hat{S})(R - \hat{R}) - \text{cov}$$

onde  $\text{cov} = E[S \cdot R] - E[S]E[R]$  captura a dependência entre stake e ROI no preditivo.

| Componente stake | Componente ROI | Interação | cov (dependência) |
|------------------|----------------|-----------|-------------------|
| USD 53.8         | USD -84.0      | USD -34.2 | USD 117.0         |

## 5. Como usar essas métricas para melhorar o modelo

**1) Correção de viés (bias correction):** manter a distribuição prevista, mas ajustar a média por um viés estimado out-of-sample (ex.: subtrair o Bias médio ou um Bias móvel).

**2) Recalibração de incerteza:** se a coverage está abaixo do nominal, os intervalos estão estreitos. Dá para corrigir escalando a dispersão (ex.: inflar desvio) ou recalibrando quantis com base em PIT.

**3) Modelar resíduos:** criar um modelo simples para  $(e_t)$  como função do contexto (nº de apostas, stake, alpha, nº de segmentos ativos, etc.) e ajustar forecast condicionalmente.

**4) Atualizar o PDF principal:** usar Bias/coverage para reportar um “cenário calibrado” conservador (lucro esperado ajustado) além do cenário base.