

Relatório — Calibração de Forecast do Modelo (PnL)

Data: 2026-01-16

Fonte numérica: forecast_calibration_global_bayes.csv (folds: 16)

1. O que estamos medindo

Para cada semana do walk-forward, o modelo escolhe regras θ_t usando apenas o passado. Em seguida medimos se a **distribuição prevista** para o PnL semanal está coerente com o **PnL teórico realizado** (aplicando θ_t na semana teste).

Importante: isso é uma calibração “teórico vs teórico”. Ela mede qualidade do modelo como gerador de decisão+previsão no dataset, mas não captura fricções de execução real (atraso, liquidez, limites dinâmicos, etc.).

2. Métricas de erro (pontuais)

Erro: $e_t = y_t - \hat{\mu}_t$, onde y_t é o PnL teórico realizado e $\hat{\mu}_t$ é a média prevista.

Bias (viés): média do erro. Se Bias < 0, o modelo está **otimista** (prevendo PnL maior do que realiza).

MAE: erro absoluto médio. Medida robusta de “tamanho típico” do erro.

RMSE: raiz do erro quadrático médio. Penaliza mais os erros grandes (sensível a outliers).

Resumo numérico (PnL semanal)

Bias	MAE	RMSE
USD -201.1	USD 489.5	USD 565.0

3. Métricas probabilísticas (calibração)

Coverage: frequência com que o realizado cai dentro do intervalo previsto. Ex.: Coverage 80% mede quantas vezes y_t cai entre p10 e p90 do preditivo. Se o modelo for bem calibrado, a coverage observada deve ficar próxima do nível nominal (80%/90%).

PIT (Probability Integral Transform): para cada semana, calcula $\text{PIT}_t = F_t(y_t)$, ou seja, a posição do realizado dentro da CDF prevista. Se a distribuição prevista for correta, os PITs ao longo do tempo se comportam como Uniforme(0,1) (média ~0,5). PIT muito baixo indica que o realizado veio pior do que o previsto; PIT muito alto indica o oposto.

CRPS (Continuous Ranked Probability Score): mede a distância entre a distribuição prevista e o realizado. Generaliza o MAE para previsões probabilísticas. **Menor é melhor.**

Coverage 80% (p10..p90)	Coverage 90% (p05..p95)	PIT (média)	CRPS (médio)
62.5%	75.0%	0.417	USD 307.2

4. Por que o PnL previsto pode “inflar” (Stake vs ROI)

Como $\text{PnL} = \text{Stake} \times \text{ROI}$, um forecast pode parecer otimista por dois caminhos:

- o modelo projeta **stake** alto (mais volume do que acontece)
- o modelo projeta **ROI** alto (retorno por dólar piora)

No nosso caso, o preditivo é gerado reamostrando semanas passadas (bootstrap Bayesiano), então o modelo aprende uma distribuição conjunta (Stake, ROI) implícita.

Decomposição (médias)

Uma decomposição útil para o erro semanal $(y - \hat{P})$ é:

$$(y - \hat{P}) = (S - \hat{S})\hat{R} + \hat{S}(R - \hat{R}) + (S - \hat{S})(R - \hat{R}) - \text{cov},$$

onde $\text{cov} = E[S \cdot R] - E[S]E[R]$ captura a dependência entre stake e ROI no preditivo.

Componente stake	Componente ROI	Interação	cov (dependência)
USD 65.7	USD -44.6	USD -46.8	USD 175.4

5. Como usar essas métricas para melhorar o modelo

1) Correção de viés (bias correction): manter a distribuição prevista, mas ajustar a média por um viés estimado out-of-sample (ex.: subtrair o Bias médio ou um Bias móvel).

2) Recalibração de incerteza: se a coverage está abaixo do nominal, os intervalos estão estreitos. Dá para corrigir escalando a dispersão (ex.: inflar desvio) ou recalibrando quantis com base em PIT.

3) Modelar resíduos: criar um modelo simples para (e_t) como função do contexto (nº de apostas, stake, alpha, nº de segmentos ativos, etc.) e ajustar forecast condicionalmente.

4) Atualizar o PDF principal: usar Bias/coverage para reportar um “cenário calibrado” conservador (lucro esperado ajustado) além do cenário base.