

Relatório — Calibração de Forecast do Modelo (PnL)

Data: 2026-01-16

Fonte numérica: forecast_calibration_global_bayes.csv (folds: 16)

1. O que estamos medindo

Para cada semana do walk-forward, o modelo escolhe regras θ_t usando apenas o passado. Em seguida medimos se a **distribuição prevista** para o PnL semanal está coerente com o **PnL teórico realizado** (aplicando θ_t na semana teste).

Importante: isso é uma calibração “teórico vs teórico”. Ela mede qualidade do modelo como gerador de decisão+previsão no dataset, mas não captura fricções de execução real (atraso, liquidez, limites dinâmicos, etc.).

2. Métricas de erro (pontuais)

Erro: $e_t = y_t - \hat{\mu}_t$, onde y_t é o PnL teórico realizado e $\hat{\mu}_t$ é a média prevista.

Bias (viés): média do erro. Se Bias < 0, o modelo está **otimista** (prevendo PnL maior do que realiza).

MAE: erro absoluto médio. Medida robusta de “tamanho típico” do erro.

RMSE: raiz do erro quadrático médio. Penaliza mais os erros grandes (sensível a outliers).

Resumo numérico (PnL semanal)

Bias	MAE	RMSE
USD -168.6	USD 475.5	USD 553.8

3. Métricas probabilísticas (calibração)

Coverage: frequência com que o realizado cai dentro do intervalo previsto. Ex.: Coverage 80% mede quantas vezes y_t cai entre p10 e p90 do preditivo. Se o modelo for bem calibrado, a coverage observada deve ficar próxima do nível nominal (80%/90%).

PIT (Probability Integral Transform): para cada semana, calcula $\text{PIT}_t = F_t(y_t)$, ou seja, a posição do realizado dentro da CDF prevista. Se a distribuição prevista for correta, os PITs ao longo do tempo se comportam como Uniforme(0,1) (média ~0,5). PIT muito baixo indica que o realizado veio pior do que o previsto; PIT muito alto indica o oposto.

CRPS (Continuous Ranked Probability Score): mede a distância entre a distribuição prevista e o realizado. Generaliza o MAE para previsões probabilísticas. **Menor é melhor.**

Coverage 80% (p10..p90)	Coverage 90% (p05..p95)	PIT (média)	CRPS (médio)
62.5%	81.2%	0.440	USD 294.5

4. Por que o PnL previsto pode “inflar” (Stake vs ROI)

Como $\text{PnL} = \text{Stake} \times \text{ROI}$, um forecast pode parecer otimista por dois caminhos:

- o modelo projeta **stake** alto (mais volume do que acontece)
- o modelo projeta **ROI** alto (retorno por dólar piora)

No nosso caso, o preditivo é gerado reamostrando semanas passadas (bootstrap Bayesiano), então o modelo aprende uma distribuição conjunta (Stake, ROI) implícita.

Decomposição (médias)

Uma decomposição útil para o erro semanal $(y - \hat{P})$ é:

$$(y - \hat{P}) = (S - \hat{S})\hat{R} + \hat{S}(R - \hat{R}) + (S - \hat{S})(R - \hat{R}) - \text{cov},$$

onde $\text{cov} = E[S \cdot R] - E[S]E[R]$ captura a dependência entre stake e ROI no preditivo.

Componente stake	Componente ROI	Interação	cov (dependência)
USD 74.1	USD -26.6	USD -36.7	USD 179.4

5. Como usar essas métricas para melhorar o modelo

1) Correção de viés (bias correction): manter a distribuição prevista, mas ajustar a média por um viés estimado out-of-sample (ex.: subtrair o Bias médio ou um Bias móvel).

2) Recalibração de incerteza: se a coverage está abaixo do nominal, os intervalos estão estreitos. Dá para corrigir escalando a dispersão (ex.: inflar desvio) ou recalibrando quantis com base em PIT.

3) Modelar resíduos: criar um modelo simples para (e_t) como função do contexto (nº de apostas, stake, alpha, nº de segmentos ativos, etc.) e ajustar forecast condicionalmente.

4) Atualizar o PDF principal: usar Bias/coverage para reportar um “cenário calibrado” conservador (lucro esperado ajustado) além do cenário base.

6. Avaliação e conclusão (o que os números significam na prática)

Estas métricas respondem duas perguntas: (i) o modelo é **otimista/pessimista** na média? (ii) o modelo está **calibrado** na incerteza (intervalos/quantis)?

No estado atual, o modelo apresenta **Bias = USD -168.6**. Bias negativo significa que, em média, o realizado ficou abaixo do previsto (otimismo). A média prevista ($E[\text{pred_mean}]$) é USD 395.8 e, ao aplicar correção de viés ($E[\text{pred_mean}] + \text{Bias}$), cai para USD 227.2. O erro típico (MAE) é USD 475.5 e o RMSE é USD 553.8: isso indica que a incerteza semanal é grande e que a previsão pontual sozinha não é suficiente para tomada de decisão.

A calibração probabilística também está fraca: Coverage 80% = 62.5% (ideal ~80%) e Coverage 90% = 81.2% (ideal ~90%). Isso sugere que os intervalos previstos estão **estritos** (subestimando risco). PIT médio = 0.440 (ideal ~0,5) reforça a assimetria para resultados piores que o previsto.

Impacto na estratégia

Quando Bias é negativo e Coverage fica muito abaixo do nominal, o efeito prático é:

- projeções de lucro tendem a estar infladas
- intervalos/quantis (p10/p90 etc.) subestimam perdas
- decisões que dependem de “p05/p10 positivo” ou de VaR estimado podem ficar excessivamente confiantes.

Antes vs depois (com correções)

cenário	mean/sem	std/sem	Sharpe ann	ROI/\$	Bias forecast	MAE	Cov80
before	192.9	499.3	2.786	0.0464	-201.1	489.5	62.5%
after	227.2	510.0	3.212	0.0540	-181.3	380.9	50.0%

Leitura: a calibração pode ser usada de duas formas.

- **Somente no reporte**: ajusta expectativas (ex.: média prevista corrigida por Bias), sem alterar o OOS realizado.
- **Dentro do otimizador**: muda seleção/stakes/cutoffs e, portanto, pode alterar (e até degradar) o OOS realizado.

Na prática, com amostra curta, é comum que usar correção por combinação diretamente no otimizador gere over-penalização. Por isso, nesta versão, recomendamos usar calibração por combinação como **monitoramento/reportage** (com shrinkage) e tratar o problema de risco principalmente via **recalibração de dispersão** (coverage/PIT).

Recomendação objetiva

Eu recomendo manter duas visões em paralelo:

- **Visão de decisão**: usar a correção por combinação de forma conservadora e com limites (shrinkage + mínimo de observações).
- **Visão de reporte**: sempre reportar também um cenário “ajustado por Bias” e uma nota explícita sobre Coverage/PIT.

Se Coverage continuar muito abaixo do nominal, a próxima evolução deve ser uma **recalibração de dispersão** (widening dos quantis/intervalos), porque hoje o problema não é só a média (Bias), mas principalmente a subestimação do risco.